

Tóm tắt nội dung: Web Scraping và Web Crawling

Ngày 25 tháng 11 năm 2025

1 Định Nghĩa và Phân Biệt Web Scraping và Web Crawling

Web Scraping và Web Crawling là hai khái niệm cốt lõi trong lĩnh vực thu thập dữ liệu tự động, thường được sử dụng cùng nhau nhưng có mục đích khác biệt.

1.1 Định Nghĩa

- **Web Crawling:** Là quá trình **tự động duyệt** và **lập chỉ mục** (indexing) các trang web bằng cách theo dõi các siêu liên kết (hyperlinks). Mục tiêu chính là *khám phá* và *xác định* các URL có sẵn trên quy mô lớn.
- **Web Scraping:** Là quá trình **tự động trích xuất** các trường dữ liệu cụ thể, có chọn lọc (như giá, văn bản, tiêu đề) từ mã nguồn HTML của một trang web đã biết hoặc đã được khám phá. Mục tiêu chính là chuyển đổi dữ liệu phi cấu trúc thành *dữ liệu có cấu trúc*.

1.2 Phân Biệt Cơ Bản

Bảng 1: So sánh Web Crawling và Web Scraping

Đặc Điểm	Web Crawling	Web Scraping
Mục đích	Khám phá và Lập chỉ mục các URL.	Trích xuất dữ liệu chi tiết, có cấu trúc.
Phạm vi	Rộng, bao phủ toàn bộ hoặc một phần lớn website.	Hẹp, tập trung vào các trường dữ liệu cụ thể.
Đầu ra	Danh sách các URL, siêu dữ liệu trang.	Dữ liệu có cấu trúc (JSON, CSV).
Vai trò	Người tìm đường (Pathfinder).	Người khai thác (Data Extractor).

2 Bài tập

Trong bài này, chúng tôi xây dựng một hệ thống đơn giản cho phép người dùng nhập vào một đường dẫn URL, tự động thu thập nội dung văn bản từ trang web, và sau đó thực

hiện hỏi–đáp dựa trên nội dung đã trích xuất. Toàn bộ quy trình bao gồm hai phần chính: (1) thu thập dữ liệu từ trang web và (2) suy luận với mô hình ngôn ngữ lớn (LLM).

2.1 Thu thập nội dung trang web

Để trích xuất dữ liệu từ URL đầu vào, hệ thống sử dụng thư viện `requests` để tải mã HTML và thư viện `BeautifulSoup` để phân tích cấu trúc trang. Tất cả văn bản của website được làm sạch bằng cách loại bỏ các ký tự trống, khoảng trắng thừa và trích xuất phần nội dung thuần văn bản. Đây là phần dữ liệu nền để LLM có thể xử lý hiệu quả.

2.2 Tích hợp LLM cho hỏi–đáp

Sau khi có nội dung trang web, hệ thống thực hiện cơ chế hỏi–đáp qua mô hình ngôn ngữ lớn. Chúng tôi sử dụng API của OpenAI với mô hình `gpt-4o-mini`, vốn là mô hình chi phí thấp nhưng mang lại chất lượng suy luận ổn định. Nội dung trang web được đưa vào như ngữ cảnh (context), trong khi câu hỏi của người dùng được truyền dưới dạng thông điệp (*message*). Mô hình sẽ trả lời dựa trên thông tin có trong đoạn văn bản đã scrape, đảm bảo câu trả lời bám sát dữ liệu gốc.

2.3 Giao diện CLI

Hệ thống được triển khai dưới dạng một giao diện dòng lệnh (CLI). Người dùng nhập URL, sau đó nhập các câu hỏi liên quan đến nội dung vừa được thu thập. CLI hỗ trợ nhiều lượt truy vấn liên tiếp và kết thúc bằng lệnh `exit`. Toàn bộ kiến trúc được triển khai gọn trong một tệp mã Python duy nhất.

2.4 Tóm tắt

Giải pháp kết hợp kỹ thuật thu thập dữ liệu web và suy luận LLM cho phép xây dựng nhanh một công cụ hỏi–đáp theo nội dung của bất kỳ trang web nào. Cách tiếp cận này đơn giản, linh hoạt và dễ mở rộng sang nhiều bài toán khác như tóm tắt trang web, tạo báo cáo, hoặc phân tích tài liệu tự động.